Liberté • Égalité • Fraternité
RÉPUBLIQUE FRANÇAISE

Premier ministre

DIRECTION
DE L'INFORMATION
LÉGALE
ET ADMINISTRATIVE

Documentation technique pour les données issues de Legifrance

SOMMAIRE

1. OBJET DE CE DOCUMENT....3
2. MAÎTRISE DU DOCUMENT....3
   2.1. Gestion des Versions....3
   2.2. Documents de référence et documents applicables....3
3. TERMINOLOGIE....3
4. PRÉAMBULE....4
5. FORMALISATION DE L'ID....4
6. ARBORESCENCE DU FLUX....5
7. CORRECTION DE DOCUMENTS DANS LE FLUX XML....5
8. SUPPRESSION DE DOCUMENTS DANS LE FLUX XML : EXEMPLE POUR LA BASE LEGI....5
9. EXTRACTION DES DELTAS....5
10. EXEMPLE D'ARBORESCENCE DES DONNÉES : LEGI....6
11. LES DTD ET LEUR DOCUMENTATION....8
12. LES STOCK....8
13. NOMS DES XML....8

1. OBJET DE CE DOCUMENT

Ce document comprend une documentation technique générique concernant les fichiers XML mis à disposition dans le cadre des licences de réutilisation des données provenant de Légifrance s'appuyant sur des exemples du fond LEGI.

2. MAÎTRISE DU DOCUMENT

2.1. Gestion des Versions

Vers./Rév.	*Date*	*Objet de la mise à jour*	*Rédacteur(s)*
1.00	17/11/2014	Initialisation	FL
1.2	11/07/2017	Corrections	PL
1.2.1	01/09/2017	Ajout fonds Acco	PL
1.2.2	18/10/2018	Ajout fonds dole	BL

2.2. Documents de référence et documents applicables

Nom du document	*Titre*	*Disponible dans*

3. TERMINOLOGIE

Terme/Sigle	*Signification*
DILA	Direction de l'Information Administrative et Légale
DIT	Département de l'informatique et des télécommunications

4. PRÉAMBULE

Les données transmises sont validées par des DTD conformes à la norme XHTML 1.0 Transitionnal.

5. FORMALISATION DE L'ID

Les éléments id représentent l'identifiant interne d'une version d'un document.

Les éléments cid représentent l'identifiant interne commun à toute les versions du document.

Le fichier XML du document porte toujours comme nom son identifiant id.

Les éléments [hierarchie_par_id] représentent la succession de répertoires générés à partir du découpage de l'identifiant interne du document :

Niveau		Description	Exemple
Niveau 1	FFFF	identifiant du fond sur 4 caractères	JORF
Niveau 2	TTTT	type du document sur 4 caractères	ARTI
Niveau 3	xx	chiffres n°1 et 2 de la séquence oracle	00
Niveau 4	xx	chiffres n°3 et 4 de la séquence oracle	00
Niveau 5	xx	chiffres n°5 et 6 de la séquence oracle	07
Niveau 6	xx	chiffres n°7 et 8 de la séquence oracle	43
Niveau 7	xx	chiffres n°9 et 10 de la séquence oracle	47
Niveau 8	FFFFTTTTxxxxxxxxxxxx.xml	fichier xml	JORFARTI000007434712.xml

6. ARBORESCENCE DU FLUX

A l'interieur de l'espace FTP se trouve un ensemble d'archives compressées tar.gz nommées selon le format suivant : Nom de la base_[timestamp].tar.gz.

Le timestamp de type <yyyymmdd>-<hhmmss> correspond au moment de l'extraction.

Il permet de connaître l'ordre dans lequel les flux ont été mis à disposition. A l'intérieur de chaque archive, on trouve les répertoires des fichiers (jorf, legi, kali, juri, jade, constit, cnil) au moment de l'extraction des données prêtes à diffuser : il y aura donc entre 1 et N répertoires. Ces répertoires sont organisés selon la hiérarchie décrite plus bas.

Le dossier de flux de time stamp contient les dossiers de la base correspondante (exemple : des dossiers JORF ou JURI ou KALI ainsi que des listes de suppression (pour les flux JORF+JURI+KALI+LEGI).

7. CORRECTION DE DOCUMENTS DANS LE FLUX XML

Dans le cas d'une correction de document, l'extracteur produit un fichier de même nom que le précédent. Il revient donc au ré utilsateur de mettre à jour son stock par simple annule et remplace du document précédent.

Comme les livraisons sont datées, il convient d'appliquer les mises à jour dans l'ordre croissant des archives compressées.

8. SUPPRESSION DE DOCUMENTS DANS LE FLUX XML : EXEMPLE POUR LA BASE LEGI

La suppression indique qu'une donnée ne doit plus être diffusée.

Elle peut aussi indiquer un changement d'état de vigueur à non vigueur pour LEGI (dans ce cas la donnée est supprimée dans la branche vigueur et recréée dans la branche non vigueur, voir le point 10).

Deux cas de figure : la donnée avait déjà été diffusée, il s'agit alors de la supprimer physiquement.
Ou alors la donnée non encore diffusée n'est pas diffusable en l'état et alors la non diffusion est une sorte de "rétention" en attente de diffusion éventuelle.

Dans les deux cas l'ordre se traduira par la présence du nom de la donnée dans une liste de suppression.
Certains ordres seront par conséquent inexécutables.

L'extracteur produit un fichier du type « liste_suppression_legi.dat » contenant une liste de chaque fichier à supprimer, leur chemin absolu et leur nom (ID de type "LEGISCTA000006160629")

Exemple
legi/global/code_et_TNC_en_vigueur/code_en_vigueur/LEGI/TEXT/00/00/06/07/40/LEGITEXT000006074096/section_ta/LEGI/SCTA/00/00/06/16/06/LEGISCTA000006160629

9. EXTRACTION DES DELTAS

Les documents des flux (exemple JORF, CASS, INCA, CAPP, CONSTIT, JADE et CNIL) sont re livrés dans leur intégralité à chaque modification des fichiers concernés.

Par exemple, la modification d'un texte (correction, suppression, enrichissement LEX) d'un JO entraîne la re livraison de l'intégralité de ce JO..

Important : dans le cas des bases LEGI et KALI les documents sont re livrés par **delta contextuel**. Ne sont exportés que la ou les branches hiérarchiques impactées par les modifications. Par exemple, la modification d'un article du code civil entraîne une extraction des fichiers suivants :

- fichiers textes et structures du code civil
- succession de tous les fichiers section_ta parentes de l'article concerné
- l'article impacté par les modifications

Tous ces éléments sont renvoyés avec toutes leurs versions.

Cas particulier : Pour la base KALI, ce mode de livraison possède un niveau supplémentaire : le conteneur.

10. EXEMPLE D'ARBORESCENCE DES DONNÉES : LEGI

```
legi/
    global/
        code_et_TNC_en_vigueur/
            code_en_vigueur/
                [hierarchie_par_cid]
                    cid texte 1/
                        article/
                            [hierarchie_par_id]
                        section_ta/
                            [hierarchie_par_id]
                        texte/
                            struct/
                                [id_texte1].XML
                                [id_texte..].XML
                            version/
                                [id_texte1].XML
                                [id_texte..].XML
                    cid texte 2/
                    ...
                    cid texte.../
            TNC_en_vigueur/
                [hierarchie_par_cid]
                    cid texte 1/
                        article/
                            [hierarchie_par_id]
                        section_ta/
                            [hierarchie_par_id]
                        texte/
                            struct/
                                [id_texte1].XML
                                [id_texte..].XML
                            version/
                                [id_texte1].XML
                                [id_texte..].XML
                    cid texte 2/
                    ...
                    cid texte.../
        code_et_TNC_non_vigueur/
            code_non_vigueur/
                idem que dans la branche en vigueur
            TNC_non_vigueur/
                idem que dans la branche en vigueur
```

Le fichier XML **LEGIARTI000006204334.xml** se situe dans le dossier 43, le chemin pour le trouver est **legi\global\code_et_TNC_en_vigueur\code_en_vigueur\LEGI\TEXT\00\00\05\62\78\LEGITEXT000005627819\article\LEGI\ARTI\00\00\06\20\43.**

Le préfixe 20090108-015451 correspond au time-stamp qui est le niveau 1er de tout flux.

11. Les DTD et leur documentation

Les DTD se trouvent dans le dossier DTD-LEGIFRANCE. Lors de chaque évolution des mises à jour le dossier est annulé et remplacé par un dossier contenant l'ensemble des DTD.

Les dtd ne sont pas versionnées.

Le dossier DTD-LEGIFRANCE contient :

- Le présent fichier de documentation technique
- Un dossier contenant l'ensemble des DTD (avec un time stamp)
    - Ex : LEGIFRANCE_20170711_dtd
- Un classeur explicitant quelles sont les DTD génériques et spécifiques pour chaque fond, quelles sont les DTD qui permettent la validation de chaque type de fichier
    - Ex : LEGIFRANCE_20170711_dtd_map.xlsx

12. LES STOCK

Le stocks de départ se trouvent dans le dossier compressé Freemium_nom de la base_timestamp.tar.gz

13. NOMS DES XML

fonds	racine du nom xml	Elément root du fichier	ce que représente l'XML
CNIL	CNILTEXT	TEXTE_CNIL	un texte
constit	CONSTEXT	TEXTE_JURI_CONSTIT	un texte
juri	JURITEXT	TEXTE_JURI_JUDI	un texte
jade	CETATEXT	TEXTE_JURI_ADMIN	un texte
jorf simple	JORFCONT	JO	un conteneur
jorf simple	JORFTEXT	TEXTE	un texte
jorf global	JORFCONT	JO	un conteneur
jorf global	JORFTEXT	TEXTE_VERSION	un texte version
jorf global	JORFTEXT	TEXTELR	un texte struct
jorf global	JORFSCTA	SECTION_TA	une section
jorf global	JORFARTI	ARTICLE	un article
LEGI	LEGITEXT	TEXTE_VERSION	un texte version
LEGI	LEGITEXT	TEXTELR	un texte struct
LEGI	LEGISCTA	SECTION_TA	une section
LEGI	LEGIARTI	ARTICLE	un article
kali	KALICONT	IDCC	un conteneur
kali	KALITEXT	TEXTE_VERSION	un texte version
kali	KALITEXT	TEXTEKALI	un texte struct
kali	KALISCTA	SECTION_TA	une section
kali	KALIARTI	ARTICLE	un article
Acco	ACCOTEXT	TEXTE_ACCO	un texte
dole	JORFDOLE	DOSSIER_LEGISLATIF	un dossier législatif